Методические указания к Проектной работе по дисциплине «Проектный практикум»

1. Цель проектной работы

В рамках дисциплины «Проектный практикум» студентам необходимо спроектировать, разработать и представить программный прототип прогнозно-аналитической системы, обеспечивающей полный цикл работы с данными: от их получения из внешних источников до формирования прогнозов и предоставления аналитической информации пользователю. Разрабатываемая система должна обеспечивать:

1. Автоматизированный сбор данных из нескольких источников.
2. Хранение исходных и обработанных данных.
3. Очистку, преобразование, объединение и подготовку данных.
4. Контроль качества поступающих и обработанных данных.
5. Построение прогнозов на основании накопленных данных.
6. Представление результатов анализа и прогнозирования в виде интерактивных дашбордов.
7. Автоматизированное и воспроизводимое выполнение основных процессов системы.

Особенность проекта заключается в повышенных требованиях к построению моделей машинного обучения и к их дальнейшему сопровождению. Помимо получения прогноза и его визуализации студент должен продемонстрировать, каким образом формируется признаковое пространство, за счёт чего модель достигает своего качества, как объясняются её отдельные решения и как система обнаруживает ухудшение качества модели с течением времени.

В рамках проекта особое внимание должно быть уделено:

— формированию признакового пространства;
— обработке слабоструктурированных данных;
— предотвращению утечки целевой переменной;
— корректности схемы валидации с учётом временного порядка

наблюдений;

— сравнению моделей различных классов с базовым решением;

— воспроизводимости экспериментов и фиксации их параметров;

— интерпретируемости решений модели;

— контролю качества модели в процессе эксплуатации.

Итогом проектной работы должна стать функционирующая прогнозно-аналитическая система, позволяющая получить актуальные данные, выполнить их обработку, сформировать прогноз исследуемого показателя и представить результаты пользователю.

2. Выбор предметной области

Предметная область проектной работы выбирается студентом самостоятельно и согласовывается с преподавателем в течение первых трех недель семестра. Обязательным условием для выбранной предметной области является:

— наличие временной составляющей данных, позволяющей решать задачу прогнозирования;

— возможность сформулировать конкретный прогнозируемый показатель;

— наличие не менее двух разнородных источников данных;

— возможность регулярного получения новых данных;

— достаточный объём исторических данных для проведения анализа и построения прогнозных моделей;

— возможность определения пользователя или группы пользователей, для которых создаётся аналитический интерфейс;

— наличие практической задачи, решение которой может быть поддержано результатами анализа и прогнозирования.

В случае затруднения в самостоятельном выборе предметной области студент вправе воспользоваться списком готовых предметных областей, однако повторение темы в рамках одной учебной группы не допускается.

№	Предметная область	Прогнозируемый показатель
1	Городская микромобильность	Число поездок велопроката/каршеринга в сутки по районам города
2	Электроэнергетика	Почасовое потребление электроэнергии в энергосистеме

		региона
3	Розничная торговля	Недельные продажи по товарным категориям сети
4	Общественный транспорт	Суточный пассажиропоток по маршрутам
5	Жилищно-коммунальное хозяйство	Потребление воды или тепла по группе домов
6	Обращения граждан	Число обращений в разрезе категорий и районов
7	Гражданская авиация	Число рейсов и доля задержек в аэропорту
8	Продовольственный рынок	Цены на плодоовощную продукцию
9	Университет	Посещаемость столовых, читальных залов, коворкингов
10	Библиотечное дело	Число книговыдач по разделам фонда
11	Эпидемиология	Недельная заболеваемость ОРВИ и гриппом в регионе
12	Аптечная розница	Спрос на группы лекарственных препаратов
13	Электронная коммерция	Спрос на товарные позиции маркетплейса
14	Складская логистика	Объём отгрузок и загрузка складских ячеек
15	Доставка готовой еды	Число заказов по зонам доставки
16	Городской трафик и такси	Спрос на поездки по районам города
17	Гостиничный бизнес	Загрузка номерного фонда и средняя цена
18	Туризм	Турпоток в регион по видам размещения
19	Фондовый рынок	Цена и объём торгов биржевого инструмента
20	Денежно-кредитная сфера	Курс валют и ставки денежного рынка
21	Рынок цифровых активов	Объём торгов и волатильность инструмента
22	Рынок недвижимости	Цена предложения за квадратный метр по районам
23	Рынок труда	Число вакансий и медианная зарплата по ИТ-специальностям
24	Промышленное оборудование	Наработка до отказа узла, число инцидентов
25	Автотранспортное предприятие	Расход топлива и пробег парка
26	Экологический мониторинг	Концентрация загрязняющих веществ
27	Водные ресурсы	Уровень воды в реке или водохранилище
28	Лесные пожары	Число активных очагов возгорания
29	Спортивная индустрия	Посещаемость матчей и продажи билетов
30	Медиа и социальные данные	Объём публикаций и упоминаний по теме

3. Обязательные компоненты системы

Первым обязательным компонентом реализуемой системы является *сбор данных*. В проекте должно использоваться не менее двух разнородных источников данных, при этом не менее одного источника должно содержать слабоструктурированные данные: тексты, журналы событий, показания датчиков, геоданные и прочее. Под разнородностью понимается различие способов получения или форматов представления данных.

Дополнительные ограничения на источники данных:

1. Инкрементальная загрузка данных — повторный запуск системы должен догружать только новые данные, ранее не записанные в систему.
2. Идемпотентность — повторный запуск любой операции в системе должен иметь одинаковый результат выполнения.

3. Устойчивость к сбоям — обработка недопустимых операций, недоступности источников данных, таймаутов, ограничений частоты запросов и прочих критериев, приводящих к неработоспособности системы.
4. Журнал загрузок — информация со сведениями о каждом запуске, параметры журнала определяются самостоятельно.

Второй обязательный компонент системы представляет собой *обработку данных и формирование признаков*. Признаки, используемые при обучении моделей и при построении прогноза в эксплуатации, должны рассчитываться единым программным кодом. Минимально должны быть выполнены:

— приведение данных к единому виду, обработка пропусков и аномальных наблюдений;
— обработка слабоструктурированного источника: векторизация текста, извлечение признаков из журналов событий либо агрегация показаний датчиков;
— формирование лаговых, оконных и календарных признаков;
— кодирование категориальных признаков с обоснованием выбранного способа;
— отбор признаков и оценка их влияния на качество модели;
— проверка отсутствия утечки целевой переменной;
— разбиение данных на обучающую и проверочную части с учётом временного порядка наблюдений и с фиксацией случайного зерна.

Третьим обязательным компонентом системы выступает *аналитический модуль*, реализованный в виде дашборда, а также не менее трёх прогнозных моделей, одна из которых является базовой: наивный прогноз или простая регрессия. Остальные модели должны относиться к различным классам алгоритмов машинного обучения. Качество моделей сравнивается по единой схеме валидации, учитывающей временной порядок наблюдений, с использованием не менее двух метрик точности, а результат сравнения дополнительно выражается в величине, понятной пользователю системы. На

дашборд выводятся фактические значения, прогноз и показатели качества модели.

Общее требование к визуализации — дашборд предназначен для принятия решения, а не для демонстрации всех доступных графиков. Каждый элемент панели должен отвечать на конкретный вопрос пользователя. Элементы, не отвечающие ни на один вопрос, подлежат удалению.

4. Компоненты системы реализуемые по выбору

Помимо трёх основных компонентов прогнозно-аналитической системы студент может реализовать следующие компоненты системы уникальные для своего профиля.

Интерпретируемость моделей. В системе необходимо реализовать возможность объяснения результатов работы модели. Минимально должны присутствовать:

- оценка важности признаков не менее чем двумя независимыми способами;
- объяснение отдельного прогноза с указанием вклада каждого признака;
- анализ зависимости прогноза от значения отдельного признака;
- сопоставление структуры важности признаков между различными периодами.

В рамках защиты студент должен объяснить средствами системы прогноз, полученный для произвольного объекта и даты, выбранных преподавателем.

Мониторинг качества модели и переобучение. Система должна обнаруживать ухудшение качества модели и управлять её версиями. Для этого необходимо реализовать:

- обнаружение изменения распределений входных данных;
- отслеживание качества модели на поступающих фактических данных;
- явно описанное правило запуска переобучения модели;
- реестр версий моделей с фиксацией состава признаков, параметров

обучения и метрик;

— правило вывода новой версии модели в эксплуатацию и возврата к предыдущей версии.

Результаты мониторинга должны сохраняться и быть доступны для анализа. В рамках защиты студент должен продемонстрировать реакцию системы на ухудшение качества модели.

Автоматизированный подбор моделей и журнал экспериментов. Система должна поддерживать воспроизводимый подбор конфигурации модели. Для этого необходимо реализовать:

— автоматизированный подбор моделей и гиперпараметров с ограничением бюджета поиска;

— журнал экспериментов с фиксацией конфигурации, версии данных, случайного зерна и полученных метрик;

— сравнение результатов экспериментов в интерфейсе системы;

— проверку итоговой модели на отложенной выборке, не участвовавшей в подборе.

В рамках защиты студент должен воспроизвести любой эксперимент из журнала по его идентификатору.

По согласованию с преподавателем студент может реализовать *собственные компоненты системы*.

5. Технологический стек

Технологический стек студент выбирает самостоятельно и обосновывает выбор в отчёте и презентации. Ограничений на язык программирования, СУБД, средство визуализации, оркестратор и прочее не накладывается: допустимы как коммерческие и облачные сервисы, так и полностью открытые решения, как готовые BI-платформы, так и собственный веб-интерфейс. Однако любой выбранный стек должен соответствовать следующим требованиям:

1. Воспроизводимость — проект разворачивается и запускается студентом самостоятельно по заранее прописанной инструкции из README файла, прикрепленного к репозиторию.

2. Автоматизация — проект запускается одной командой, последовательностью команд или по расписанию, без ручного копирования файлов.
3. Конфигурируемость — обязательно использование конфигурационных файлов и/или переменных окружения.
4. Открытость данных — используемые источники данных должны быть общедоступными либо синтетически сгенерированными, использование персональных данных не допускается.

6. Состав материалов проектной работы

Состав материалов проектной работы перед защитой проекта включает в себя:

1. Репозиторий с исходным кодом проекта, демонстрирующий работу с проектом на протяжении всего семестра. Работам, загруженным несколькими коммитами в конце семестра по усмотрению преподавателя, может быть снижен балл.
2. README файл с описанием выбранной архитектуры, стеком и инструкцией по развертыванию.
3. Схема архитектуры системы, включающая в себя: источники данных, слои хранения, компоненты обработки, модель прогноза, средство визуализации, потоки данных между ними.
4. Отчет, содержащий следующие разделы: постановка задачи, описание предметной области, данных, решения по обработке данных, описание моделей и результаты валидации, описание реализованных уникальных компонентов профиля, выводы и ограничения работы. Дополнительные разделы могут быть добавлены по согласованию с преподавателем.
5. Презентация с демонстрацией работы проекта. Состав презентационных материалов студент выбирает самостоятельно.
6. Работающий прототип системы.

Все материалы должны быть загружены в соответствующую область ЛМС не позднее озвученного преподавателем срока.

7. Критерии оценивания

Работа оценивается по стобалльной шкале. Баллы озвучиваются после защиты проекта студентом. Процесс составления отчета и презентации, а также защиты проекта является обязательным. Состав оцениваемых компонентов представлен в Таблице ниже.

Компонент	Что оценивается	Баллы
Источники данных	Число и разнородность источников, наличие слабоструктурированных данных, инкрементальность, идемпотентность, устойчивость к сбоям, журнал загрузок	10
Обработка данных и формирование признаков	Качество витрины признаков, глубина признакового конструирования, обработка слабоструктурированного источника, отбор признаков, доказанное отсутствие утечки целевой переменной	15
Модельное ядро	Наличие базовой модели, разнообразие классов моделей, корректность схемы валидации, воспроизводимость обучения, интерпретация метрик и их перевод в понятную пользователю величину	15
Аналитика данных	Дашборд, читаемость, наличие разрезов и фильтров, совместное отображение факта, прогноза и качества модели, автоматическое обновление	10
Компоненты, реализуемые по выбору	Обоснование и реализация дополнительных компонентов системы	30
Технологическое исполнение проекта	Использование выбранного технологического стека	5
Отчет и защита проекта	Умение составить техническую документацию, а также доклад по проекту	15
Итого		**100**

Преподавателем, проводящим защиту, может дополнительно выставлено 10 баллов по своему усмотрению.

8. Порядок защит

Порядок защит проектов озвучивается преподавателем, ведущим семинарские занятия.